

Régression logistique

Analyse multidimensionnelle appliquée

Léo Belzile

HEC Montréal

Expliquer le comportement de la moyenne d'une variable binaire $Y \in \{0, 1\}$ en utilisant un modèle de régression avec p variables explicatives $X_1, \dots, X_p$.

$$\underbrace{E(Y = 1 \mid X)}_{\text{moyenne théorique}} = \underbrace{\Pr(Y = 1 \mid X)}_{\text{probabilité de succès}} = p$$

Par convention, les zéros représentent des échecs et les uns des succès (même si $Y = 1$ signifie mourir).

Si la variable réponse Y vaut soit 0, soit 1, on peut postuler une loi Bernoulli pour Y , soit

$$\Pr(Y = y) = p^y(1 - p)^{1-y}, \quad y = 0, 1.$$

Il en découle que $E(Y) = p$ et $Va(Y) = p(1 - p)$.

La variabilité est complètement déterminée par la moyenne.

Questions comprenant une variable réponse binaire:


- est-ce qu'un client potentiel a répondu favorablement à une offre promotionnelle?
- est-ce qu'un client est satisfait du service après-vente?
- est-ce qu'une firme va faire faillite au cours des trois prochaines années?
- est-ce qu'un participant à une étude réussit une tâche?

Pourquoi pas une régression linéaire?

Les modèles linéaires ne sont pas adéquats pour les variables binaires.

- Sans contrainte, on peut obtenir des probabilités négatives ou supérieures à 1!
- Les données binaires ne respectent pas le postulat d'égalité des variances
 - Plus la probabilité de succès est près de 0.5, plus la variabilité est élevée.
 - Cette hétérogénéité invalide les résultats des tests d'hypothèse pour les coefficients.

Modèle linéaire vs logistique



On considère une fonction pour la moyenne $E(Y_i \mid X_i)$ en fonction des variables explicatives.

Dans une régression linéaire, le prédicteur linéaire

$$\eta = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

représente la moyenne de la variable réponse.

Or, la probabilité doit être dans $[0, 1]$, et $\eta \in \mathbb{R} = (-\infty, \infty)$.

On peut appliquer une transformation au prédicteur linéaire


$$\eta = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

pour que la prédiction soit entre zéro et un.

On considère la fonction sigmoïde (expit),

$$p = \text{expit}(\eta) = \frac{\exp(\eta)}{1 + \exp(\eta)} = \frac{1}{1 + \exp(-\eta)}.$$

Courbe sigmoïde



On voit que p est une fonction nonlinéaire croissante de $\eta = \beta_0 + \dots + \beta_p X_p$.

- Si β_j est positif et X_j augmente, $\Pr(Y = 1)$ augmente aussi.
- Si β_j est négatif et X_j augmente, $\Pr(Y = 1)$ diminue.
-

Quelques propriétés de la fonction exponentielle:

- $\exp(0) = 1$
- $\exp(a + b) = \exp(a) \exp(b)$
- $\exp(ab) = \exp(a)^b$

Quelques propriétés de la fonction logarithmique

- $\ln(1) = 0,$
- $\ln(\exp(x)) = x$ (fonction inverse)
- $\ln(ab) = \ln(a) + \ln(b)$

Si on applique la transformation inverse, on obtient

$$\ln \left(\frac{p}{1-p} \right) = \eta = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p.$$

ou, en prenant l'exponentielle de chaque côté,

$$\text{cote} = \frac{p}{1-p} = \exp(\beta_0) \cdots \exp(\beta_p X_p)$$

Modèle multiplicatif pour la cote.

La cote est utilisée dans les paris sportifs

$$\text{cote}(p) = \frac{p}{1-p} = \frac{\Pr(Y = 1 \mid X)}{\Pr(Y = 0 \mid X)}.$$

Table 1: Cote et probabilité de succès

p	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9
cote	$\frac{1}{9}$	$\frac{1}{4}$	$\frac{3}{7}$	$\frac{2}{3}$	1	$\frac{3}{2}$	$\frac{7}{3}$	4	9

Interprétation de l'ordonnée à l'origine en termes de cote

Si $X_1 = \dots = X_p = 0$, il est clair que

$$\text{cote}(Y \mid X = 0_p) = \exp(\beta_0)$$

et

$$\Pr(Y = 1 \mid X = 0_p) = \frac{\exp(\beta_0)}{1 + \exp(\beta_0)}$$

représente la probabilité que $Y = 1$ quand $X = 0_p$.

Comme pour la régression linéaire, $X_1 = \dots = X_p = 0$ peut être impossible; dans ce cas, β_0 ne s'interprète pas.

Dans le modèle logistique, le rapport de cotes quand $X_k = x_k + 1$ versus $X_k = x_k$ quand $X_j = x_j$ ($j = 1, \dots, p, j \neq k$) est


$$\begin{aligned} & \frac{\text{cote}(Y \mid X_k = x_k + 1, X_j = x_j, j \neq k)}{\text{cote}(Y \mid X_k = x_k, X_j = x_j, j \neq k)} \\ &= \frac{\exp\left(\beta_0 + \sum_{j=1}^p \beta_j x_j + \beta_k\right)}{\exp\left(\beta_0 + \sum_{j=1}^p \beta_j x_j\right)} \\ &= \exp(\beta_k). \end{aligned}$$

Quand X_k augmente d'une unité et que la valeur de toutes les autres covariables est constante, la cote de Y est multipliée par $\exp(\beta_k)$.


- La cote augmente si $\exp(\beta_k) > 1$, c'est-à-dire si $\beta_k > 0$.
- La cote diminue si $\exp(\beta_k) < 1$, c'est-à-dire si $\beta_k < 0$.

Une étude de Duke et Amir (2023) dans Marketing Science considère l'utilisation d'un format de vente - intégré (choisir directement d'acheter et la quantité en une seule étape, versus - séquentiel, le standard actuel (séquentiel), qui revient à choisir d'acheter (oui ou non), puis sélectionner la quantité.

Sequential Screen



Integrated Screen



Les données de l'expérience 3 contiennent 399 observations des variables suivantes

- format: variable expérimental, soit intégré ou séquentiel
- achat: variable binaire, 1 pour achat
- quantite: quantité en cas d'achat (0, 1 ou 2)
- marque: nom de la première marque (pour un item vs deux), soit for your beauty ou beauty care, contrebalancé
- genre: genre, masculin ou féminin (4 valeurs manquantes)
- age: âge du répondant

Comme les participants sont assignés de manière aléatoire à chaque sous-groupe de `format`, seule cette variable et l'ordre de la `marque` peuvent avoir une incidence.

Les variables sociodémographiques `genre` et `age` sont uniquement collectées pour vérifier la représentativité de l'échantillon et la généralisabilité des conclusions.

Ajustement du modèle

La fonction `glm` dans R ajuste un modèle linéaire généralisé (par défaut, linéaire avec `family = gaussian`).

- L'argument `family=binomial(link="logit")` permet de spécifier que l'on ajuste un modèle logistique.

```
1 data(formatvente, package = "hecmulti")
2 # Données de l'expérience 3 de Duke et Amir (2023)
3 modele1 <- glm(formula = achat ~ format,
4                 family = binomial(link = "logit"),
5                 data = formatvente)
```

```
1 summary(modele1)
```

On obtient un tableau résumé avec les coefficients (`summary`)

Si on a plusieurs variables explicatives, les coefficients sont interprétés en modifiant une variable à la fois.

On compare deux profils identiques, sauf pour la variable en question

- toute chose étant égale par ailleurs
- *ceteris paribus*

La variable catégorielle

$$X_1 = I_{\text{format} = \text{séquentiel}} = \begin{cases} 1, & \text{format} = \text{séquentiel} \\ 0, & \text{format} = \text{intégré (réf.)} \end{cases}$$

Le modèle ajusté en terme de cote est

$$\frac{\Pr(Y = 1 \mid X_1 = 1)}{\Pr(Y = 0 \mid X_1 = x_1)} = \exp(1.053) \exp(-0.449).$$

- Lorsque qu'on passe d'un format intégré à un format séquentiel, la cote est multipliée par $\exp(-0.449) = 0.638$. C'est une diminution de la cote de 36.2%. La probabilité d'achat est plus faible pour le format séquentiel que le format intégré.

Pour un modèle probabiliste donné, on peut calculer la « probabilité » d'avoir obtenu les données de l'échantillon.

Si on traite cette « probabilité » comme une fonction des paramètres, on l'appelle vraisemblance.

L'estimateur du maximum de vraisemblance est la valeur du vecteur de paramètres qui maximise la fonction de vraisemblance. Ce sont les valeurs qui rendent les données les plus plausibles.

La vraisemblance d'une observation $Y_i \in \{0, 1\}$ (loi Bernoulli/binomiale) est

$$L(\boldsymbol{\beta}; y_i) = p_i^{y_i} (1 - p_i)^{1-y_i} = \begin{cases} p_i & y_i = 1 (\text{succès}) \\ 1 - p_i & y_i = 0 (\text{échec}) \end{cases}$$

et où

$$p_i = \text{expit}(\eta_i) = \frac{\exp(\beta_0 + \beta_1 \mathbf{x}_{i1} + \dots + \beta_p \mathbf{x}_{ip})}{1 + \exp(\beta_0 + \beta_1 \mathbf{x}_{i1} + \dots + \beta_p \mathbf{x}_{ip})}.$$

- Si les observations sont indépendantes, la probabilité conjointe d'avoir un résultat donné est le produit des probabilités pour chaque observation.
- Il n'y a pas de solution explicite pour $\hat{\beta}_0, \dots, \hat{\beta}_p$ dans le cas de la régression logistique: il faut maximiser la vraisemblance.

- Pour des raisons de stabilité numérique, on maximise le logarithme naturel $\ell(\beta) = \ln L(\beta)$ de la log vraisemblance conjointe de l'échantillon (transformation monotone croissante).
- La log vraisemblance est simplement la somme des contributions individuelles.
- On utilise la log vraisemblance ℓ comme mesure d'ajustement et pour construire des tests d'hypothèse.

Des estimés des coefficients $\hat{\beta}$ découlent une estimation de $\Pr(Y = 1)$ pour les valeurs $X_1 = x_1, \dots, X_p = x_p$ d'un individu donné,

$$\hat{p} = \text{expit}(\hat{\beta}_0 + \dots + \hat{\beta}_p x_p).$$

Un modèle avec uniquement l'ordonnée à l'origine retournera $\hat{p}$, la proportion empirique de succès. Comme pour la régression linéaire, c'est la moyenne des observations.

Pour les modèles ajustés par maximum de vraisemblance.

Comparaison de modèles emboîtés

- Modèle complet (sous l'alternative) avec p variables explicatives
- Modèle restreint (sous l'hypothèse nulle) sur lequel on impose $k \leq p$ restrictions.
- Par exemple, retirer une variable catégorielle à K niveaux revient à enlever $k = K - 1$ coefficients.



Comparons un modèle avec et sans marque.

Variable catégorielle à deux niveaux (un coefficient associé).

```
1 modele2 <- glm(formula = achat ~ format,  
2               family = binomial(link = "logit"),  
3               data = formatvente)
```

On teste l'hypothèse nulle $\mathcal{H}_0 : \beta_2 = 0$, où

$X_2 = I_{\text{marque}=\text{for your beauty}}$. L'hypothèse alternative est que le coefficient est non-nul.

Le test est basé sur la statistique

$$D = -2\{\ell(\hat{\beta}_0) - \ell(\hat{\beta})\}.$$

Cette différence D , lorsque l'hypothèse $\mathcal{H}_0$ est vraie, suit approximativement une loi khi-deux χ_k^2 .

Si la valeur p est inférieure au seuil de signification, typiquement $\alpha = 0.05$, on rejette l'hypothèse nulle.

Exemple de test

```
1 # modèle 1 (alternative), modèle 2 (H0)
2 anova(modele2, modele1, test = "LR")
```

Analysis of Deviance Table

Model 1: achat ~ format

Model 2: achat ~ format + marque

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	397	487.07			
2	396	486.22	1	0.85229	0.3559

```
1 ## Deviance = -2*log vraisemblance
2 rvrais <- modele2$deviance - modele1$deviance
3 pchisq(rvrais, df = 1, lower.tail = FALSE) # valeur-p
```

```
[1] 0.3559062
```

On conclut que la variable explicative X_2 (ordre de la marque) n'est pas statistiquement significative.

Tester la significativité des variables

Si un paramètre n'est pas significativement différent de zéro, cela veut dire qu'il n'y a pas de lien significatif entre la variable et la réponse une fois que les autres variables sont dans le modèle.

```
1 car::Anova(modele1, type = 2)
```

Analysis of Deviance Table (Type II tests)

Response: achat

	LR	Chisq	Df	Pr(>Chisq)
format	4.2738	1		0.0387 *
marque	0.8523	1		0.3559

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

On peut aussi considérer des intervalles de confiance pour les coefficients individuels.

Ceux obtenus par défaut dans R sont appelés intervalles de confiance de vraisemblance profilée.

```
1 confint(modele1)      # IC pour beta
2 exp(confint(modele1)) # IC pour exp(beta)
```

Ces intervalles sont invariants aux reparamétrisation: si $[b_i, b_s]$ est l'intervalle de vraisemblance profilée pour β , l'intervalle pour $\exp(\beta)$ est simplement $[\exp(b_i), \exp(b_s)]$.

Intervalle de confiance




Figure 1: Intervalles de confiance profilés de niveau 95% pour les coefficients du modèle logistique (échelle exponentielle).

Comme $\exp(\cdot)$ est une transformation monotone croissante,

$$\beta > 0 \quad \Longleftrightarrow \quad \exp(\beta) > 1.$$

Si la valeur postulée, par exemple $\mathcal{H}_0 : \beta_j = 0$ ou $\exp(\beta_j) = 1$, est dans l'intervalle de confiance de niveau $1 - \alpha$, on ne rejette pas l'hypothèse nulle.

Coefficients pour données complètes

variables	cote	95% CI	valeur-p
format			0.039
intégré	—	—	
séquentiel	0.64	0.41, 0.98	
marque			0.4
beauty care	—	—	
for your beauty	0.82	0.53, 1.25	

Il est difficile de départager l'effet individuel d'une variable explicative lorsqu'elle est fortement corrélée avec d'autres.

La multicollinéarité ne dépend pas de la variable réponse Y , mais de la matrice X du modèle. Ce sont donc les mêmes diagnostics qu'en régression linéaire (MATH 6O619): considérer les facteurs d'inflation de la variance (`car::vif`).

```
1 car::vif(modele1)
```

```
format  marque  
1.000292 1.000292
```

Pas d'inquiétude ici, coefficients faibles (inférieurs à 5)

Si Y est continue et qu'on cherche à estimer $\Pr(Y > c \mid X)$ pour une valeur c donnée, il n'est pas recommandé de dichotomiser Y via

$$Y^* = \begin{cases} 1, & Y > c; \\ 0, & Y \leq c. \end{cases}$$

et d'ajuster une régression logistique.

Pourquoi? On perd de l'information.

On peut estimer plutôt une régression linéaire et prendre

$$\Pr(Y > c \mid X) = \Phi \left(\frac{\hat{\mu} - c}{\hat{\sigma}} \right),$$

où

- $\hat{\mu} = \hat{\beta}_0 + \dots + \beta_p X_p$ est la moyenne prédite pour le profil donné,
- $\hat{\sigma}$ est l'estimation de l'écart-type
- $\Phi(\cdot)$ est la fonction de répartition d'une loi normale standard (pnorm dans R)




Figure 2: Régression linéaire simple et densité normale à différentes valeurs de x .

Il arrive que, lors de l'ajustement d'une régression logistique, on obtienne un message d'avertissement:


```
1 Warning messages:
2 1: glm.fit: algorithm did not converge
3 2: glm.fit: fitted probabilities numerically 0 or 1 occurred
```

Le deuxième message d'erreur survient quand une combinaison linéaire de variables explicatives permet de prédire exactement la réponse: nos probabilités prédites sont 0 ou 1.

- par exemple, si on ajuste un modèle pour achat en fonction de quantite.

```
1 modele_qs <- glm(  
2   achat ~ quantite,  
3   data = formatvente,  
4   family = binomial)
```

Illustration de la séparation de variables



Quasi-séparation de variable: les estimations des paramètres sont presque infinies pour permettre une transition abrupte de la probabilité de succès de $\hat{p} = 0$ à $\hat{p} = 1$ à $x = 0.5$.

Les valeurs élevées des coefficients et erreurs-type sont une autre indication de quasi-séparation de variables.

Avec des variables standardisées, un coefficient $|\beta_j| > 10$ est suspect.

Table 3: Modèle logistique pour achat en fonction de quantite.

	coef.	erreur-type
cst	-25.2	16510.5
quantite	49.7	20687.2

Typiquement, le problème survient parce que

- on a ajouté un dérivé de la variable réponse comme variable explicative
- on a un modèle surajusté, souvent une variable catégorielle pour laquelle toutes les observations d'un niveau donné ont la même réponse, soit 0 ou 1.

Ce n'est pas nécessairement un enjeu pour la prédiction, mais c'est souvent indicateur de problèmes plus importants. Les coefficients et interprétations ne sont plus valides...

1. Regarder quelles probabilités sont presque 0 ou 1 pour identifier les observations problématiques et s'assurer que l'échantillon que l'on emploie est adéquat.
 - Par exemple, les femmes ne peuvent pas avoir un cancer de la prostate, donc la probabilité prédite pour ces dernières est 0. On pourrait simplement enlever les femmes et prédire zéro manuellement.
2. Déterminer si une variable explicative cause du surajustement en étudiant les coefficients dont la valeur absolue est très élevée.

- Souvent, seules les données agrégées sont disponibles et on a accès au nombre de réussites (sur m essais).
- On peut utiliser la loi binomiale pour le modèle logistique en ajoutant le nombre d'essais au modèle.
- L'interprétation des paramètres reste identique.

Si les données représentent la somme d'événements Bernoulli indépendants, la loi du nombre de réussites $Y \in \{0, \dots, m\}$ sur le nombre d'essais m est binomiale avec fonction de masse

$$\Pr(Y = y) = \binom{m}{y} p^y (1 - p)^{m-y}, \quad y = 0, 1.$$

La vraisemblance pour un échantillon $\text{Bin}(m, p)$ est à constante près la même que pour un échantillon aléatoire de m variables Bernoulli indépendantes.

L'espérance (moyenne théorique) est $E(Y) = mp$ et la variance $\text{Va}(Y) = mp(1 - p)$.

Pour les données agrégées, on doit spécifier comme variable réponse (l'argument de gauche avant le `~` dans la formule) une matrice avec deux colonnes, contenant

- les y succès
- les $m - y$ échecs.

```
1 formatvente_agg <- formatvente |>
2   dplyr::group_by(format) |>
3   dplyr::summarise(succes = sum(achat),
4                     echec = sum(1-achat))
5 modele1 <- glm(
6   cbind(succes, echec) ~ format,
7   family = binomial,
8   data = formatvente_agg)
9 anova(modele1)
```

Exemple: succès pour les examens de conduite

On considère le taux de succès dans 346 centres pour examens de conduite pratique en Grande-Bretagne; les données datent de 2018.

An easy ride? Scottish village fuels debate on driving test pass rates

New figures reveal that it is far easier to pass driving test in Highlands than in inner city Birmingham



▲ The 86.5% pass rate in Gairloch is stratospheric compared with urban areas, while the national average is 45.8%.
Photograph: Peter Jolly/for the Guardian


761 750 personnes ont réussi l'examen pratique, pour 1 663 897 essais.

- Un article du journal The Guardian a suggéré que le taux de réussite était significativement plus élevé dans la campagne écossaise.

Puisque nous n'avons pas de classification des centres de test ruraux/urbains, on utilise le nombre d'examens passés comme proxy.

Les autres variables explicatives sont le sexe de l'individu et la région en Angleterre; toutes les subdivisions d'Écosse et du Pays de Galles sont regroupées par royaume.

Rural test centres tend to have higher pass rates than ones in cities



- Une régression logistique sert à modéliser la moyenne de variables catégorielles, typiquement binaires.
- C'est un cas particulier d'un modèle de régression linéaire généralisée (GLM)

Le modèle est interprétable à l'échelle de la cote

- La cote donne le rapport probabilité de réussite (1) sur probabilité d'échec (0)
- Interprétation en terme de
 - pourcentage d'augmentation si $\exp(\hat{\beta}) > 1$, avec $\exp(\hat{\beta}) - 1$.
 - pourcentage de diminution si $\exp(\hat{\beta}) < 1$, avec $1 - \exp(\hat{\beta})$

- L'estimation par maximum de vraisemblance permet l'usage des tests d'hypothèse basés sur la déviance.
- Si on teste un seul paramètre, on peut également effectuer le test en regardant si la valeur postulée pour β se trouve dans l'intervalle de confiance de vraisemblance profilée, qui est invariant aux reparamétrisations.