

Analyse exploratoire

Analyse multidimensionnelle appliquée

Léo Belzile

HEC Montréal




Figure 1: Adapté de *R for Data Science*, H. Wickham et G. Grolemund

Quelques bonnes pratiques

Data Organization in Spreadsheets

Karl W. Broman^a and Kara H. Woo^b

^aDepartment of Biostatistics & Medical Informatics, University of Wisconsin-Madison, Madison, WI; ^bInformation School, University of Washington, Seattle, WA

ABSTRACT

Spreadsheets are widely used software tools for data entry, storage, analysis, and visualization. Focusing on the data entry and storage aspects, this article offers practical recommendations for organizing spreadsheet data to reduce errors and ease later analyses. The basic principles are: be consistent, write dates like YYYY-MM-DD, do not leave any cells empty, put just one thing in a cell, organize the data as a single rectangle (with subjects as rows and variables as columns, and with a single header row), create a data dictionary, do not include calculations in the raw data files, do not use font color or highlighting as data, choose good names for things, make backups, use data validation to avoid data entry errors, and save the data in plain text files.

ARTICLE HISTORY

Received June 2017
Revised August 2017

KEYWORDS

Data management; Data organization; Microsoft Excel; Spreadsheets

Karl W. Broman & Kara H. Woo (2018) Data Organization in Spreadsheets, The American Statistician, 72:1, 2-10, DOI: 10.1080/00031305.2017.1375989

Nettoyage des données

- Toujours garder une copie des données brutes
- Automatiser le nettoyage



Rohan Alexander
@RohanAlexander

Friends don't let friends use Excel.
Official data release of the 2019 Kenyan census: knbs.or.ke/?wpdmpromo=2019-...
BTW clean and tidy version coming soon :)

Traduire le Tweet


Table 2.3: Distribution of Population by Age, Sex*, County and Sub-County
KEURURUWEN

Age	Male	Female	Total	Age	Male	Female	Total
0	42875	45156	88131	51	452	450	902
1	790	765	1555	52	501	537	1038
2	754	780	1534	53	379	447	826
3	627	641	1268	54	473	463	936
4	888	781	1669	55-54	2,327	2,496	4823
5	819	827	1,646	55	449	524	973
6	4058	3,994	8,052	56	497	502	999
7	848	839	1,687	57	380	463	843
8	879	884	1,763	58	327	376	703
9	972	889	1,861	59	404	423	827
10	882	945	1,827	59-58	2,057	2,288	4345
11	1038	915	1,953	60	434	501	935
12	926	948	1,874	61	328	373	701
13	896	899	1,829	62	289	299	588
14	996	896	1,892	63	250	247	447
15	996	896	1,892	64	181	186	347



Ethan Mollick
@emollick

A third of all genetics papers published in Nature over a decade (and 20% across all journals) had errors due to the fact that many gene have names like SEPT2 (the official name of Septin 2), which were automatically coded as dates by Microsoft Excel.
genomebiology.biomedcentral.com/articles/10.11...



8:23 PM · 12 mars 2021 · Twitter for iPad



Figure 2: Capture d'écran d'un article du quotidien *The Guardian*

Certains types de données méritent une attention particulière

- Séries chronologiques ou longitudinales: corrélation
- Données de sondage: pondération
- Données de survie: information incomplète

Données en format "propre"

- variables en colonnes
- observations en lignes
- une seule mesure par cellule

country	year	cases	population
Afghanistan	1999	1845	197071
Afghanistan	2000	1866	2095360
Brazil	1999	31737	17206362
Brazil	2000	84488	17404898
China	1999	212258	127215272
China	2000	27766	12858583

variables

country	year	cases	population
Afghanistan	1999	1845	197071
Afghanistan	2000	1866	2095360
Brazil	1999	31737	17206362
Brazil	2000	84488	17404898
China	1999	212258	127215272
China	2000	27766	12858583

observations

Quel est le format de ces données de la Régie de l'Énergie?

Régions	HEBDOMADAIRE												
	janvier				février				mars				
	2022-01-03	2022-01-10	2022-01-17	2022-01-24	2022-01-31	2022-02-07	2022-02-14	2022-02-21	2022-02-28	2022-03-07	2022-03-14	2022-03-21	2022-03-28
1. Bas-Saint-Laurent	148,2	150,6	151,1	151,4	160,8	164,7	165,6	166,0	166,1	196,7	185,5	182,0	185,3
2. Saguenay-Lac-Saint-Jean	138,6	141,3	146,6	146,4	151,6	153,8	153,7	155,7	156,5	190,1	175,8	170,1	173,0
3. Capitale-Nationale	149,8	149,8	154,6	154,7	161,4	161,8	166,5	166,7	168,2	195,0	181,5	178,8	180,9
4. Mauricie	148,3	148,3	152,8	153,2	155,2	159,7	162,2	164,3	164,7	193,2	182,8	178,4	183,3
5. Estrie	146,9	147,6	148,6	149,4	152,8	156,7	159,0	159,8	161,9	188,2	184,6	178,5	183,7
6. Montréal	151,8	152,5	156,1	156,5	161,9	167,3	170,3	166,5	170,6	196,1	182,1	184,6	181,5
7. Outaouais	140,6	143,2	145,0	147,7	152,0	155,4	157,3	157,0	158,7	184,1	182,3	174,4	180,9
8. Abitibi-Témiscamingue	148,9	148,9	149,6	149,9	153,4	159,3	160,8	164,4	164,4	193,8	183,9	179,2	179,4
9. Côte-Nord	146,2	147,9	149,5	153,6	159,2	160,7	163,5	163,3	164,4	193,8	185,4	176,8	181,7
10. Nord-du-Québec (excl. Nunavik)	158,6	160,1	162,5	163,6	166,8	169,2	173,9	174,0	174,9	204,1	192,4	189,2	194,2
11. Gaspésie-Îles-de-la-Madeleine	151,7	153,2	155,7	156,6	161,7	167,7	168,7	167,8	168,1	195,2	186,6	184,1	181,3
12. Chaudière-Appalaches	148,8	148,8	153,4	153,0	161,2	161,1	165,4	165,5	165,9	194,8	180,9	178,7	179,2
13. Laval	151,7	152,0	156,7	157,1	162,5	167,8	170,8	166,7	170,8	196,3	182,3	185,3	182,1
14. Lanaudière	146,8	146,9	150,2	152,0	155,7	159,7	161,3	160,5	165,3	190,4	181,5	180,4	179,6
15. Laurentides	148,0	148,7	151,2	152,9	156,3	161,0	163,5	162,0	164,6	189,8	180,6	181,3	180,6
16. Montérégie	148,4	149,2	151,8	153,1	157,4	161,7	164,9	162,6	165,8	192,6	181,7	181,6	180,1
17. Centre-du-Québec	148,7	148,8	150,2	151,3	154,1	158,4	159,2	159,7	164,7	190,1	182,5	178,5	182,6
MOYENNE PONDERÉE	148,0	148,8	151,8	152,7	157,6	161,2	163,7	163,1	165,4	192,7	182,0	179,9	180,7

Types de variables



Figure 3: Allison Horst (CC BY 4.0)

Vérifier la présence de

- valeurs manquantes (NA, points, cellules vides, 999, -1, etc.)
- relations logiques (total, moyenne, etc.) entre variables
- variables catégorielles non déclarées
 - valeur entière (par ex., jours de la semaine)
 - chaînes de caractère

97	14	.0	.0	100.0
98	2	.0	.0	100.0
99	4	.0	.0	100.0
100	4	.0	.0	100.0
102	2	.0	.0	100.0
104	1	.0	.0	100.0
105	1	.0	.0	100.0
Total	45968	99.9	100.0	
missing 998	61	.1		
999	2	.0		
Total	63	.1		
Total	46031	100.0		

Quel est l'avantage des graphiques?

Un simple graphique transmet plus d'information à l'analyste que n'importe quel autre option

John Tukey

Pourquoi créer des graphiques?


Les résumés numériques focalisent l'attention sur les valeurs attendues, les résumés graphiques sur les valeurs inattendues.

John Tukey

Qu'est ce qu'un bon graphique?

communique des idées complexes avec clarté, précision et efficacité ... le graphique qui offre au lecteur le plus grand nombre d'idées le plus rapidement possible avec le moins d'encre et le plus petit espace possible

Edward Tufte, 1983



- Éléments (couches):
 - données
 - application (variable → esthétique)
 - objets géométriques
 - transformations
 - positionnement
- Échelle / guide
- Coordonnées (facettes, système de coordonnées)

Pour une visualisation effective:

1. le choix du graphique dépend du type de variable
2. soignez les apparences
3. portez une attention particulière à la perception visuelle humaine

Règle 1: choix de graphiques


Avec une variable:

- continue: histogramme, densité
- discrète: diagramme en bâton
- catégorielle: diagramme en bâton (fréquence ou pourcentage)

Avec deux variables


- continues: nuage de points
- catégorielles: diagramme à bande (avec couleurs), carte thermique
- continue $\times$ catégorielle: boîte à moustache, graphique violon

Répartition des billets de train selon la classe




Répartition du prix des billets de train

billets au tarif Promo entre Barcelone et Madrid.





La boîte donne

- les quartiles q_1, q_2, q_3 (50% des données dans la boîte),
- les moustaches à 1.5 fois l'écart interquartile $q_3 - q_1$,
- les valeurs des observations au delà des moustaches.



Prix de billets de train au tarif Promo (en euros)





- Qu'est-ce qui cloche dans la représentation graphique précédente?
- Comment pourrait-on remédier aux problèmes soulevés?

Certaines visualisations sont plus efficaces/adéquates que d'autres

- votre graphique doit être interprétable uniquement avec la légende
- inclure les noms de variables **et** les unités
- ajouter une description dans le texte et faire une référence croisée

- Titre et annotation
- Libellés et unités sur les axes
- Libellé de l'axe des y en sous-titre
- Inverser les axes si les étiquettes trop longue (variable catégorielles)

Règle 3: perception visuelle humaine

- attention au ratio longueur/largeur
- le texte doit être lisible (taille de la police)
- espace entre bandes
- étendu des axes (inclure ou pas zéro)
- choix de couleurs
 - noir/blanc avec contraste
 - palettes pour daltoniens
- comparaison d'aires/superficies (difficile)
- graphiques 3D / avec rotation superflue à proscrire

Problèmes de perceptions



Donald J. Trump
@realDonaldTrump

Follow

In addition to Florida - South Carolina, North Carolina, Georgia, and Alabama, will most likely be hit (much) harder than anticipated. Looking like one of the largest hurricanes ever. Already category 5. BE CAREFUL! GOD BLESS EVERYONE!

7:51 AM - 1 Sep 2019

18,075 Retweets 73,811 Likes




14K 18K 74K



Mauvaise palette de couleur

- Gauche: Carte originale de la NOAA en niveaux de gris: on voit clairement le problème de saturation
- Droite: solution potentielle avec palette de couleurs différente.



1. Formuler des questions
 2. Chercher des réponses à ces questions à l'aide de
 - statistiques descriptives
 - tableaux de contingence
 - graphiques
 3. Infirmer ou confirmer nos intuitions
 4. Raffiner les questions suite aux observations
 5. Répéter le processus
- Écrire un résumé des trouvailles et des aspects **importants** uniquement.

Pour aller plus loin:

- Chapitre 1 de *Data Visualization: A practical introduction* par Kieran Healy
- *Fundamentals of Data Visualization* par Claus O. Wilke
- Chapitre 1 *Data Visualization* de **R** for Data Science (2e edition) par Hadley Wickham, Mine Çetinkaya-Rundel et Garrett Grolemund

L'Association du transport aérien international (IATA) est une regroupement de compagnies aériennes commerciales de passagers dont le siège social est situé à Montréal.

Parmi leurs programmes, un vise à prédire la turbulence atmosphérique claire, une cause importante de coûts en raison de

- blessures lors de vol
- consommation plus importante de carburant (déviation de trajectoire)
- usure accrue des avions

Depuis une dizaine d'années, les avions sont dotés de senseurs qui permettent de mesurer l'intensité de la turbulence atmosphérique mesurée via le taux de dissipation des tourbillons, ou EDR (unités de mesure en $\text{m}^{2/3}/\text{s}$).

Les mesures sont basées sur un algorithme développé par le centre national de recherche atmosphérique (NCAR) décrit dans ce rapport technique.

Depuis 2018, l'IATA a développé une plateforme pour traquer en temps réel les zones de turbulence d'air propre, une des principales causes de blessures dans les avions.




Figure 4: Capture d'écran de l'interface du gadget Turbulence Aware
(©IATA)

Les avions mesurent toutes les minutes la moyenne et le maximum d'EDR, ainsi que

- l'heure,
- l'identifiant du vol,
- la température,
- la direction et la force des vents,
- la localisation 3D (longitude, latitude, altitude)

Transmettre et stocker toutes ces données est coûteux, et la plupart des mesures d'EDR sont faibles ou nulles.

Les avions sauvegardent durant le vol les données à des intervalles réguliers (battement) de 15 ou 20 minutes, et pendant les périodes de turbulence

- type 1: si le maximum dépasse $0.18\text{m}^{2/3}/\text{s}$ à temps t , les valeurs chaque minute entre $t - 5$ minutes et $t + 6$ minutes (12 mesures).
- type 2: si le maximum dépasse $0.12\text{m}^{2/3}/\text{s}$ pour trois des six dernières minutes, les valeurs chaque minute entre $t - 5$ minutes et $t + 6$ minutes (12 mesures).
- type 3: si la moyenne dépasse $0.06\text{m}^{2/3}/\text{s}$ pour quatre minutes des six dernières, on enregistre $t - 5, \dots, t$ (6 mesures)

- Comment l'échantillonnage (complexe) affecte les rapports?
- Les aéroports (départ et arrivée) ne sont pas répartis uniformément sur le globe: comment ça peut affecter les résultats?

Certaines mesures ne sont pas à des intervalles réguliers:
exemple d'un avion à


1:32, 1:34, 1:35, 1:36, 1:37, 1:45, 2:00, 2:08, 2:09, 2:11, 2:12, 2:13, 2:15,
2:45...

Pouvez-vous deviner la fréquence des battements?

Données manquantes et valeurs aberrantes

Certaines valeurs de covariables (température) sont implausibles.

Des valeurs manquantes de température sont exactement zéro (à de plus hautes altitudes).



- Format des base de données
- Types de variables (numériques, catégorielles) et nature des données
- Première étape: nettoyage, validation des données et analyse exploratoire
- Utilisation judicieuse de graphiques dans les rapports